G検定（JDLA ジェネラリスト検定）　シラバス2024　7　#04

教師あり学習

回帰問題・分類問題・多クラス分類、線形回帰・単回帰と重回帰・ロジスティック回帰、サポートベクターマシン・マージン最大化・カーネルとカーネルトリック・決定木、アンサンブル学習・ブートストラップサンプリング・バギング・ランダムフォレスト・ブースティング・勾配ブースティング、AR モデル・VAR モデル

各ページの下に、根拠にした資料（JDLA のシラバス、scikit-learn User Guide、ウィキペディア日本語版・英語版）を書いた。『』の中は原文どおり

第1章

回帰と分類

特徴量と正解のペアから、入力 → 正解の関係を学ぶ。

回帰と分類、線形のモデル

問題	出力	例
回帰	数値（量）	家の価格
2クラス分類	どちらか	迷惑メールか
多クラス分類	3つ以上	数字 0〜9（one-vs-rest など）

線形回帰
残差平方和が最小の直線（最小二乗法）。説明変数1つ＝単回帰、2つ以上＝重回帰

ロジスティック回帰
重みの合計 → シグモイド → 確率 0〜1 → しきい値 0.5 で分類

> ロジスティック「回帰」だが主に分類。シグモイドの単純パーセプトロンと等価。

出典：ウィキペディア「教師あり学習」『教師あり学習に属する代表的なタスクとして回帰と分類がある。』／「線形回帰」／「ロジスティック回帰」／scikit-learn「Linear Models」「Multiclass and multioutput algorithms」

第2章

サポートベクターマシンと決定木

境界を広く取るか、条件で分けるか。

SVM と決定木

SVM
境界と一番近いデータ（サポートベクター）の距離＝マージンを最大に

↓ 直線で分けられないとき

カーネル法
高次元の特徴空間に写像。計算はカーネル関数で済ませる（カーネルトリック）

> ハードマージン（誤りを許さない）とソフトマージン（少し許す）。

決定木
条件で枝分かれ。分類にも回帰にも使える

長所	短所
理由がわかる（ホワイトボックス）・前処理が少ない	木が複雑になりすぎて過学習しやすい

出典：scikit-learn「Support Vector Machines」『SVMs decision function (detailed in the Mathematical formulation) depends on some subset of the training data, called the support vectors.』／ウィキペディア「カーネル法」「決定木」／scikit-learn「Decision Trees」

第3章

アンサンブル学習と時系列

弱いモデルも、組み合わせれば強くなる。

バギングとブースティング

元の訓練データ

↓ ブートストラップ（復元抽出）で何組も

木1 | 木2 | 木3 …（並列）

↓ 平均・多数決

バギング → ランダムフォレスト
さらに特徴量もランダムな一部だけ

学習器1 → 間違えたデータの重みを上げる

↓（順番に）

学習器2 → …

↓ 足し合わせ

ブースティング → AdaBoost・勾配ブースティング
勾配ブースト木は通常ランダムフォレストより高精度

出典：ウィキペディア「バギング」「ブートストラップ法」「ランダムフォレスト」「ブースティング」『従って、新たに追加される弱い学習器は、それまでの弱い学習器が誤分類していた例に注目することになる。』／「勾配ブースティング」／scikit-learn「Ensembles」

時系列のモデル

モデル	扱う変数	中身	例
AR モデル（自己回帰）	1つ	時点 t の値を、自分の過去の値で表す	過去7日の売上 → 明日の売上
VAR モデル（ベクトル自己回帰）	複数	複数の変数の過去の値で、それぞれの今を表す	気温と電力需要を互いに使う

「自己回帰」は時系列のモデル。ロジスティック回帰や重回帰とは別。

出典：ウィキペディア「自己回帰モデル」『自己回帰モデル（じこかいきモデル、英: autoregressive model）は時点 t におけるモデル出力が時点 t 以前のモデル出力に依存する確率過程である。』／Wikipedia「Vector autoregression」

本番での問われ方

ねらい	見るところ
問題の種類	回帰と分類の見分け、多クラス分類
モデルのしくみ	ロジスティック回帰は分類、SVM はマージン最大化とカーネルトリック、決定木は解釈しやすいが過学習
アンサンブル	バギング（並列・ブートストラップ・平均）とブースティング（順番・誤りを重視）、ランダムフォレストは特徴量もランダム
時系列	AR は1変数、VAR は複数の変数

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」7. 教師あり学習