G検定（JDLA ジェネラリスト検定）　シラバス2024　8　#05

教師なし学習

クラスタリング・k-means 法・ウォード法・デンドログラム、次元削減・主成分分析（PCA）・特異値分解（SVD）・多次元尺度構成法（MDS）・t-SNE、協調フィルタリング・コンテンツベースフィルタリング・コールドスタート問題、トピックモデル・潜在的ディリクレ配分法（LDA）

各ページの下に、根拠にした資料（JDLA のシラバス、scikit-learn User Guide、ウィキペディア日本語版・英語版）を書いた。『』の中は原文どおり

第1章

クラスタリング

正解のないデータを、似たものどうしのグループに分ける。

k-means 法と階層型クラスタリング

① k 個の中心を置く（k は先に決める）

↓

② 各データを一番近い中心のクラスタへ

↓

③ 中心をクラスタの平均に動かす → ②へ（変わらなくなるまで）

非階層型。イナーシャ（クラスタ内平方和）を小さく。初期値で結果が変わる（k-means++）。

階層型：近いクラスタを1つずつ併合

ウォード法
併合後のクラスタ内の2乗誤差の合計が最小の組を選ぶ

デンドログラム（樹形図）
根＝全データ、葉＝データ1つ。切る高さでクラスタ数

出典：ウィキペディア「k平均法」『本アルゴリズムでは最小値ではなく初期値依存の極小値に収束する。』／「クラスター分析」／scikit-learn「Clustering」

第2章

次元削減

情報をなるべく残して、変数の数を減らす。

次元削減の手法

手法	しくみ	ポイント
主成分分析（PCA）	分散が最大の方向から順に、直交する主成分を作る	線形。寄与率で情報量を見る
特異値分解（SVD）	どんな形の行列も3つの行列の積に分解	大きい特異値だけ残して近似。文書×単語なら LSA
多次元尺度構成法（MDS）	距離の関係を保って低次元に並べる	古典的 MDS＋ユークリッド距離＝PCA
t-SNE	近いものを近くに、t 分布で2・3次元に埋め込む	非線形。可視化が主な目的

出典：ウィキペディア「主成分分析」『相関のある多数の変数から相関のない少数で全体のばらつきを最もよく表す主成分と呼ばれる変数を合成する多変量解析の一手法』／「特異値分解」「多次元尺度構成法」「t分布型確率的近傍埋め込み法」／scikit-learn

第3章

推薦とトピックモデル

行動の似た人から、言葉の出方から、隠れた構造を見つける。

推薦のしくみ

協調フィルタリング
好みが似た利用者（行動の相関が高い人）の記録から推薦

コールドスタート問題：新しい利用者・新しい商品・新しいサービスには記録がない。

コンテンツベースフィルタリング
商品の特徴（ジャンル・作者）と利用者の好みを比べる

記録がなくても使えるので、新商品のコールドスタートを補える。似たものばかりになりやすい。

出典：ウィキペディア「協調フィルタリング」『協調フィルタリング（きょうちょうフィルタリング、Collaborative Filtering、CF）は、多くのユーザの嗜好情報を蓄積し、あるユーザと嗜好の類似した他のユーザの情報を用いて自動的に推論を行う方法論である。』／「推薦システム」／Wikipedia「Cold start (recommender systems)」

トピックモデルと LDA

文書A：犬 骨 散歩 犬 …

文書B：猫 ニャー 犬 …

↓ 単語の出方から

トピック「犬」・トピック「猫」

潜在的ディリクレ配分法（LDA）
1つの文書は複数のトピックの混ざり。単語はトピックから出てくる

> 線形判別分析（教師あり）も LDA と略す。別物。

出典：ウィキペディア「トピックモデル」／「潜在的ディリクレ配分法」『各文書は複数のトピックから構成され、単語の出現は特定のトピックに基づいていると仮定される。』

本番での問われ方

ねらい	見るところ
クラスタリング	k-means（非階層・k を先に・初期値依存）、ウォード法とデンドログラム（階層型）
次元削減	PCA（分散最大・直交）、SVD、MDS、t-SNE（非線形・可視化）の違い
推薦	協調フィルタリングとコンテンツベース、コールドスタート問題
トピック	トピックモデル、LDA は1文書に複数トピック

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」8. 教師なし学習