G検定（JDLA ジェネラリスト検定）　シラバス2024　9　#06

強化学習

エージェント・環境・状態・行動・報酬・方策・マルコフ決定過程・割引率、探索と活用・バンディットアルゴリズム・ε -greedy 方策・UCB 方策、状態価値関数・行動価値関数・Q学習・SARSA・方策勾配法・REINFORCE・Actor-Critic・モデルフリー

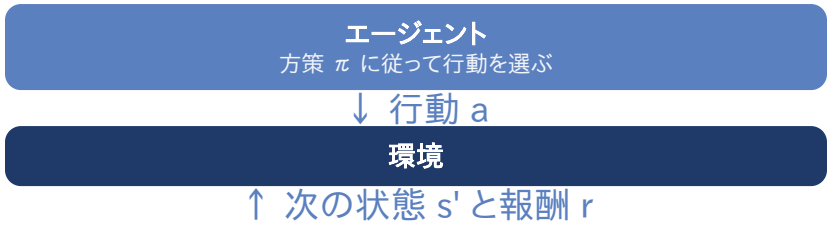
各ページの下に、根拠にした資料（JDLA のシラバス、Sutton・Barto「Reinforcement Learning: An Introduction」第2版、OpenAI「Spinning Up in Deep RL」、ウィキペディア日本語版）を書いた。『』の中は原文どおり

第1章

強化学習のしくみ

正解はない。報酬を手がかりに、試行錯誤で行動のしかたを学ぶ。

エージェントと環境



目的：将来までの報酬の合計（収益）を最大にする方策を見つける。

言葉	中身
マルコフ決定過程	状態・行動・遷移確率・報酬で表す。次の状態は今の状態と行動だけで決まる（マルコフ性）
割引率 γ	0〜1。k 先の報酬は γ^(k−1) 倍。小さいほど目先重視。無限の和が収束する

出典：ウィキペディア「強化学習」『強化学習シナリオの典型的な構成: エージェントは環境内で行動をおこし、それは報酬や状態の表現に解釈され、エージェントにフィードバックされる。』／「マルコフ決定過程」／Sutton・Barto／Spinning Up

探索と活用

活用（exploitation）
今までで一番よい行動を選ぶ

探索（exploration）
もっとよい行動を探して別の行動を試す

どちらかに偏るとだめ → トレードオフ。単純な例が多腕バンディット問題（スロットマシン）。

方法	選び方
greedy	いつも一番よさそうな行動（探索なし）
ε-greedy	確率 ε でランダム、1−ε で一番よい行動。ε 大＝探索多
UCB	価値の推定＋不確かさ（試した回数が少ないほど大）

出典：Sutton・Barto『The agent has to exploit what it has already experienced in order to obtain reward, but it also has to explore in order to make better action selections in the future.』／ウィキペディア「多腕バンディット問題」「強化学習」

第2章

価値の学習と方策の学習

価値から行動を決めるか、方策を直接学ぶか。

価値関数と Q学習・SARSA

関数	中身
状態価値関数 V(s)	状態 s から方策に従ったときの収益の期待値
行動価値関数 Q(s,a)	状態 s で行動 a をとったときの収益の期待値（Q値）

	Q学習	SARSA
更新に使う	次の状態の最大の Q値	次に実際に選んだ行動の Q値
型	方策オフ	方策オン
由来	ワトキンス 1989	S・A・R・S・A の頭文字

> Q学習＋ディープラーニング＝DQN（#16）。

出典：ウィキペディア「Q学習」『Q学習は強化学習の方策オフ型時間差分法の一つである。』／「SARSA」／Sutton・Barto

方策を直接学ぶ

アプローチ	学ぶもの	代表	ポイント
価値ベース	Q(s,a)	Q学習・SARSA・DQN	データを使い回せてサンプル効率がよい
方策ベース	方策 π そのもの	方策勾配法・REINFORCE（ウィリアムズ 1992）	連続した行動に強い。方策オンが多い
両方	Actor（方策）＋Critic（価値）	Actor-Critic・A3C	Critic の評価で Actor を更新

> モデルフリー＝環境のモデルを使わない（Q学習・SARSA・方策勾配法）。モデルベース＝使う。

出典：Sutton・Barto『All methods that follow this general schema we call policy gradient methods, whether or not they also learn an approximate value function.』／Spinning Up「Kinds of RL Algorithms」

本番での問われ方

ねらい	見るところ
しくみ	エージェント・環境・報酬・方策、マルコフ決定過程とマルコフ性、割引率
探索と活用	バンディット、ε-greedy（ε の意味）、UCB（不確かさ）
価値ベース	状態価値と行動価値、Q学習（オフ・最大値）と SARSA（オン・実際の行動）
方策ベース	方策勾配法、REINFORCE、Actor-Critic、モデルフリー

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」9. 強化学習