G検定（JDLA ジェネラリスト検定）　シラバス2024　10　#07

モデルの選択・評価

汎化性能・訓練誤差・汎化誤差・過学習・未学習・バイアスとバリアンス、訓練／検証／テストデータ・ホールドアウト検証・k分割交差検証・LOOCV・層化、混同行列・正解率・適合率・再現率・F値・ROC曲線・AUC、MSE・RMSE・MAE・AIC・BIC・オッカムの剃刀

各ページの下に、根拠にした資料（JDLA のシラバス、scikit-learn User Guide、ウィキペディア日本語版）を書いた。『』の中は原文どおり

第1章

汎化と過学習

めざすのは訓練データの成績ではなく、未知のデータでの成績（汎化性能）。

過学習と未学習

未学習（過少適合）
単純すぎる。訓練誤差も汎化誤差も大きい

ちょうどよい
訓練誤差も汎化誤差も小さい

過学習（過剰適合）
複雑すぎる。訓練誤差は小さいが汎化誤差が大きい

> サイン：訓練誤差は下がり続けるのに、検証誤差が上がり始める。

原因	対策
データに比べモデルが複雑	データを増やす・データ拡張（#13）
パラメータが多すぎる	正則化・ドロップアウト・早期終了（#09）
評価のしかた	交差検証で確かめる（第2章）

出典：ウィキペディア「過剰適合」『その原因の一つとして、統計モデルへの適合の媒介変数が多すぎる等、訓練データの個数に比べて、モデルが複雑で自由度が高すぎることがある。』

バイアスとバリアンス

バイアス（かたより）
予測の平均が本当の値からずれる。単純すぎると大

バリアンス（ばらつき）
データが変わると予測が大きく変わる。複雑すぎると大

汎化誤差の期待値 ＝ バイアス ＋ バリアンス ＋ ノイズ（ノイズはモデルで減らせない）

モデル	バイアス	バリアンス
単純（次数が低い）	大	小 → 未学習
複雑（次数が高い）	小	大 → 過学習

片方を減らすと、もう片方が増える=トレードオフ。

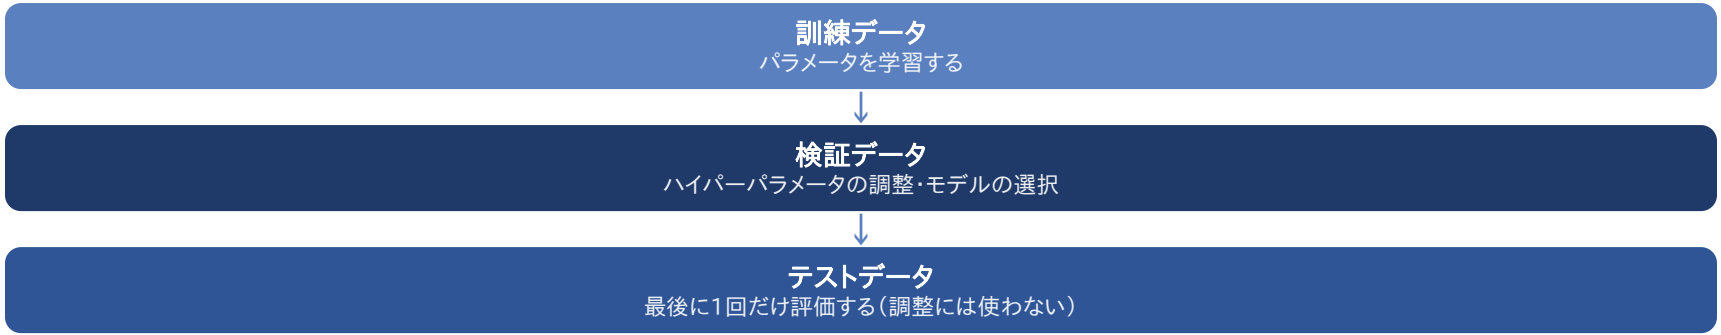
出典：ウィキペディア「偏りと分散」『バイアス-バリアンス分解（bias–variance decomposition）とは、汎化誤差の期待値をバイアス+バリアンス+ノイズの3つの和に分解することである。』

第2章

データの分け方と検証

学習・調整・評価で、使うデータを分ける。

訓練・検証・テスト



データリーケージ：テストデータや正解の情報が学習に紛れこむと、評価だけ高く出て本番で性能が出ない。

出典：scikit-learn『training proceeds on the training set, after which evaluation is done on the validation set, and when the experiment seems to be successful, final evaluation can be done on the test set.』

ホールドアウト検証と交差検証

方法	分け方	特徴
ホールドアウト検証	訓練用と評価用に1回だけ分ける	簡単。分け方で結果がぶれる。一般に交差検証には入れない
k分割交差検証	k 個に分け、評価用を入れ替えて k 回	k 回の平均で評価。データを無駄にしにくいが計算は k 倍
一個抜き（LOOCV）	1件だけ評価用、残り全部で訓練	k＝データ数。計算量が最大
層化 k 分割	各分割のクラスの割合をそろえる	クラスの数がかたよったデータ向き

> 交差検証をしても、最後の評価用のテストデータは別に取っておく。

出典：ウィキペディア「交差検証」『ただし一般にホールドアウト検証は交差検証には分類されない。』／scikit-learn『A test set should still be held out for final evaluation, but the validation set is no longer needed when doing CV.』

第3章

分類の評価指標

指標はすべて混同行列の4つの数から計算する。

混同行列と指標

	予測：陽性	予測：陰性
実際：陽性	真陽性 TP	偽陰性 FN（見逃し）
実際：陰性	偽陽性 FP（誤検知）	真陰性 TN

> 真/偽＝予測が当たったか。陽性/陰性＝予測した側。

指標	式
正解率	(TP＋TN)÷全体
適合率	TP÷(TP＋FP)　誤検知を減らしたい
再現率	TP÷(TP＋FN)　見逃しを減らしたい
F値	適合率と再現率の調和平均

出典：ウィキペディア「混同行列」『予測分析において、混同表（混同行列と呼ばれることもある）とは、2行2列の表で、真陽性、真陰性、偽陽性、偽陰性の数を表したものである。』

正解率のわな／ROC曲線と AUC

1,000件中 陽性10件
全部「陰性」と答えると…

↓

正解率 99%
でも再現率は 0%

クラスがかたよったデータは、正解率だけで判断しない。

ROC曲線
しきい値を変え、横軸＝偽陽性率、縦軸＝真陽性率

AUC
ROC曲線の下の面積。1 が最良、ランダムは 0.5

偽陽性率＝FP÷(FP＋TN)＝1−特異度

出典：ウィキペディア「受信者操作特性」『AUC が 1 のときが最良であり、ランダムで全く無効なモデルでは 0.5 となる。』

第4章

回帰の評価とモデルの選び方

当てはまりだけでなく、複雑さも考えて選ぶ。

回帰の指標と情報量規準

名前	中身	ポイント
MSE	誤差の2乗の平均	大きな外れに敏感
RMSE	MSE の平方根	元のデータと同じ単位
MAE	誤差の絶対値の平均	外れ値の影響が小さい
AIC	−2×最大対数尤度＋2×パラメータ数	最小のモデルを選ぶ。パラメータ数を過大に見積もりがち
BIC	−2×最大対数尤度＋パラメータ数×log(データ数)	罰が重く、より単純なモデルを選ぶ

> オッカムの剃刀：同じくらい説明できるなら、仮定（パラメータ）の少ない単純なモデルを選ぶ。

出典：ウィキペディア「赤池情報量規準」『具体的にはAIC最小のモデルを選択すれば、多くの場合、良いモデルが選択できる』／「オッカムの剃刀」『「ある事柄を説明するためには、必要より多くを仮定するべきでない」とする指針。』

本番での問われ方

ねらい	見るところ
汎化	過学習と未学習の見分け、原因、バイアスとバリアンスのトレードオフ
検証	訓練・検証・テストの役割、ホールドアウトと k 分割・LOOCV・層化
分類の指標	混同行列から計算、適合率と再現率の使い分け、F値、ROC曲線と AUC
回帰・選択	MSE・RMSE・MAE の違い、AIC・BIC は小さいほどよい、オッカムの剃刀

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」10. モデルの選択・評価