G検定（JDLA ジェネラリスト検定）　シラバス2024　15・16　#10

誤差逆伝播法と最適化手法

誤差逆伝播法・連鎖律・信用割当問題・勾配消失／爆発、勾配降下法・学習率・SGD・バッチ／ミニバッチ／オンライン学習・エポック・イテレーション・局所最適解・鞍点、モーメンタム・AdaGrad・RMSprop・AdaDelta・Adam・AdaBound・AMSBound、ハイパーパラメータ・グリッドサーチ・ランダムサーチ・二重降下現象・ノーフリーランチ定理

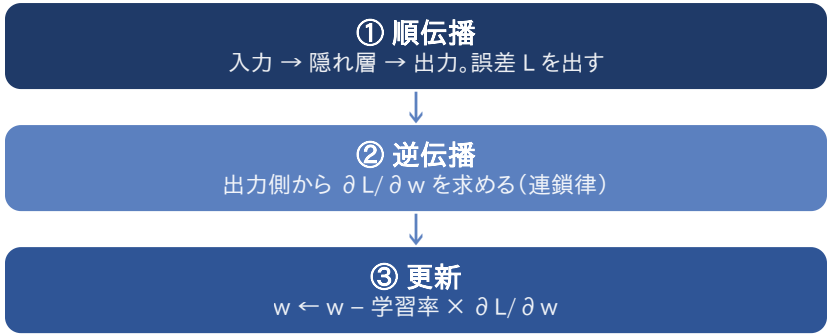
各ページの下に、根拠にした資料（JDLA のシラバス、Adam・ADADELTA・AdaBound・Deep Double Descent・Random Search の論文、ウィキペディア）を書いた。『』の中は原文どおり

第1章

誤差逆伝播法

出力側から勾配をさかのぼって求め、勾配降下法で重みを直す。

順伝播と逆伝播



言葉	中身
連鎖律	合成関数の微分＝各微分の積
信用割当問題	どの重みが誤差にどれだけ責任があるか → 勾配で答える
勾配消失／爆発	積が重なり、小さく消える／大きく発散（#08）

> 逆伝播＝勾配を求める。更新するのは SGD など（まとめて呼ぶことも多い）。

出典：ウィキペディア「誤差逆伝播法」『バックプロパゲーションは数理モデルであるニューラルネットワークのパラメータに関する偏微分を計算する手法で、確率的勾配降下法はパラメータを更新する（学習する）手法である。』

第2章

勾配降下法と学習の単位

傾きの逆へ、学習率の歩幅で少しずつ下る。

バッチ・ミニバッチ・オンライン

学び方	1回の更新に使うデータ	特徴
バッチ学習（最急降下法）	全部	安定。1回が重い
ミニバッチ学習	数十〜数百件	いまの標準
オンライン学習（SGD）	1件	速いがばらつく。局所解から抜けやすい

エポック＝データ全体を1回使う。イテレーション＝1回の更新。
6,000件・バッチ100 → 1エポック＝60イテレーション

学習率：大きすぎると発散、小さすぎると遅い。

出典：ウィキペディア「確率的勾配降下法」『全てではないが複数の訓練データで勾配を計算する方法をミニバッチと言う。』『学習率を大きくしすぎると発散し、小さくしすぎると収束まで遅くなる。』

局所最適解と鞍点

大域最適解
全体で一番低い点（ほしいもの）

局所最適解
近くでは一番低いが、全体では一番でない谷

鞍点
ある方向では極小、別の方向では極大。勾配 0 で停滞（プラトー）

勾配降下法は傾きだけを見るので、局所最適解や鞍点で止まりやすい。

対策：SGD のばらつき、モーメンタム（慣性で通り抜ける）、学習率の工夫。

出典：ウィキペディア「最急降下法」『勾配法のため、局所的な最小値に捉まり易く、大域的な最小値を求めるのは困難であることが欠点である。』／「鞍点」

第3章

最適化アルゴリズム

勢いをつける（モーメンタム）か、パラメータごとに歩幅を変える（適応的な方法）か。

SGD の改良の系譜

名前	工夫	弱点・ねらい
モーメンタム	前回の更新を慣性として足す	谷の振動を抑え、鞍点を抜ける
AdaGrad（2011）	勾配の2乗の合計で割る（パラメータごと）	学習率がだんだん 0 → 止まる
RMSprop（2012）	勾配の2乗の指数移動平均で割る	AdaGrad の「止まる」を改良
AdaDelta（2012）	次元ごとに自動調整	学習率を手で決めなくてよい
Adam（2014）	勾配の移動平均 m ＋ 2乗の移動平均 v	モーメンタム＋RMSprop。いまの定番
AdaBound・AMSBound（2019）	学習率に狭まる上限・下限	後半は SGD に近づけ、汎化の差をなくす

出典：英語版ウィキペディア「Stochastic gradient descent」『it keeps not just one, but two running averages for each parameter: m of the gradient, v of the squared gradient.』／Luo ほか（AdaBound）／Zeiler（ADADELTA）

第4章

ハイパーパラメータの調整

人が決める値は、検証データで探す。

探し方と学習のふしぎ

方法	やり方
グリッドサーチ	候補の全組み合わせ（数が爆発）
ランダムサーチ	範囲からランダムに。同じ計算量でより効率的
ベイズ最適化	結果から次の候補を選ぶ

ハイパーパラメータ：学習率・バッチサイズ・エポック数・層の数・正則化の強さ など

二重降下現象
モデルを大きくすると、テスト性能が悪化 → 再び改善。エポック数でも起きる

ノーフリーランチ定理
どの問題にも最強の万能アルゴリズムはない

出典：Bergstra・Bengio『randomly chosen trials are more efficient for hyper-parameter optimization than trials on a grid.』／Nakkiran ほか「Deep Double Descent」

本番での問われ方

ねらい	見るところ
逆伝播	連鎖律、勾配を求める役と更新する役、信用割当問題、勾配消失・爆発の原因
勾配降下法	学習率、バッチ／ミニバッチ／オンライン、エポックとイテレーションの計算、局所解と鞍点
最適化手法	モーメンタム、AdaGrad→RMSprop→Adam の改良点、AdaDelta、AdaBound・AMSBound
ハイパーパラメータ	グリッドとランダム、二重降下、ノーフリーランチ

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」15. 誤差逆伝播法／16. 最適化手法