G検定（JDLA ジェネラリスト検定）　シラバス2024　17～21　#11

畳み込み・正規化・プーリング・スキップ結合

全結合層・畳み込み操作・カーネル・特徴マップ・ストライド・パディング・受容野、Dilated（Atrous）・Depthwise Separable・1×1 畳み込み、バッチ／レイヤー／インスタンス／グループ正規化、最大値・平均値プーリング・GAP、スキップ結合・ResNet

各ページの下に、根拠にした資料（JDLA のシラバス、ResNet・Batch／Layer／Group／Instance Normalization・Dilated Convolutions・Xception・MobileNets・NIN の論文、ウィキペディア）を書いた。『』の中は原文どおり

第1章

全結合層と畳み込み層

全部とつながるか、狭い範囲と同じ重みでつながるか。

全結合層と畳み込み層のちがい

	全結合層	畳み込み層
つながり	前の層の全ユニット（受容野＝全体）	狭い範囲だけ（局所的な受容野）
重み	組ごとに別	同じカーネルを全体で共有
パラメータ数	入力×出力＋出力（200→50 なら 10,050）	K×K×入力ch×出力ch＋出力ch（3×3, 3→16 なら 448）
向くデータ	特徴のベクトル	画像・音声（近くどうしに関係）

> 畳み込み層のパラメータ数は入力画像の大きさによらない。学習するのはカーネルとバイアス。

出典：英語版ウィキペディア「Convolutional neural network」『In a convolutional layer, each neuron receives input from only a restricted area of the previous layer called the neuron's receptive field.』／日本語版『カーネルとバイアスが学習対象である。』

畳み込みの計算

入力（画像）

↓ カーネル（フィルタ）をストライドずつずらし、積の和

特徴マップ
カーネル1枚 → 1チャネル

出力の1辺 ＝（入力＋2×パディング−カーネル）÷ストライド＋1

入力	K	P	S	出力
28	3	0	1	26
28	3	1	1	28（同じ大きさ）
28	2	0	2	14（半分）

パディング＝ふちに 0 を足す。ストライド大 → 出力が小さく。

出典：英語版ウィキペディア「Convolutional neural network」『In general, setting zero padding to be P=(K−1)/2 when the stride is S=1 ensures that the input volume and output volume will have the same size spatially.』

いろいろな畳み込み

名前	中身	ねらい・使用例
Dilated（Atrous）	カーネルの要素のあいだに間をあける	パラメータを増やさず受容野を広げる。解像度を保つ → セグメンテーション
Depthwise Separable	チャネルごとの空間の畳み込み → 1×1 畳み込み	計算量・パラメータを大きく削減。Xception・MobileNets
1×1（pointwise）	各点でチャネル方向の全結合	チャネル数を変える。Inception

出典：Yu・Koltun『dilated convolutions support exponential expansion of the receptive field without loss of resolution or coverage.』／Chollet「Xception」『a depthwise convolution followed by a pointwise convolution』

第2章

正規化層

どこで平均と分散をとるかで名前が変わる。

4つの正規化

正規化	平均・分散をとる範囲	向く場面・弱点
バッチ正規化	ミニバッチの全サンプル × チャネルごと	画像の CNN。小さいバッチで不正確
レイヤー正規化	1サンプル × 層の全部	RNN・Transformer。バッチによらない
インスタンス正規化	1サンプル × 1チャネル	スタイル変換
グループ正規化	1サンプル × チャネルのグループ	小さいバッチ（物体検出など）

バッチ正規化：内部共変量シフトを抑える。大きな学習率が使え、初期値に鈍感になり、正則化の効果も。

出典：Ioffe・Szegedy『Batch Normalization allows us to use much higher learning rates and be less careful about initialization.』／Wu・He『GN divides the channels into groups and computes within each group the mean and variance for normalization.』

第3章

プーリング層とスキップ結合

小さくまとめて位置ずれに強く。近道を作って深く。

プーリング層

窓 2×2：1, 5, 3, 7

↓

最大値プーリング → 7
いまの基本形

平均値プーリング → 4
ネオコグニトロン・LeNet

グローバルアベレージプーリング（GAP）
特徴マップ1枚 → その平均1つ

平らにして全結合層に入れるかわりに使える → パラメータが大幅に減る（NIN で提案）。

プーリング層には学習するパラメータがない。位置ずれへの不変性を得る。

出典：日本語版ウィキペディア「畳み込みニューラルネットワーク」『現代では、最大値プーリングが基本形であるが、これも色々なバリエーションがある。』／Lin ほか「Network In Network」

スキップ結合と ResNet

入力 x

↓ 層（重み → ReLU → 重み）で F(x)

出力 ＝ F(x) ＋ x
x はスキップ結合でそのまま足す

層は残差 F(x)=H(x)−x を学ぶ。

逆伝播で勾配が近道 x を通る → 勾配消失が起きにくい。

ResNet（He ほか、2015）
152層。ILSVRC 2015 分類 1位（誤差 3.57%）

出典：He ほか『We explicitly reformulate the layers as learning residual functions with reference to the layer inputs, instead of learning unreferenced functions.』／ウィキペディア「残差ネットワーク」

本番での問われ方

ねらい	見るところ
畳み込み層	全結合層とのちがい、パラメータ数、出力サイズの計算、ストライドとパディング
畳み込みの変種	Dilated は受容野、Depthwise Separable は軽量化
正規化層	どの範囲で平均・分散をとるか、バッチ正規化の効果と弱点
プーリング・スキップ結合	最大値・平均値・GAP、不変性、残差学習と勾配の近道

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」17. 全結合層〜21. スキップ結合