G検定（JDLA ジェネラリスト検定）　シラバス2024　22・23　#12

RNNとAttention

RNN・時系列データ・エルマン／ジョルダンネットワーク・双方向 RNN・BPTT・教師強制・勾配消失／爆発、LSTM・ゲート機構・GRU、Seq2Seq・エンコーダ・デコーダ・Attention・クエリ／キー／バリュー・Source-Target Attention、Transformer・Self-Attention・Multi-Head Attention・位置エンコーディング・マスク

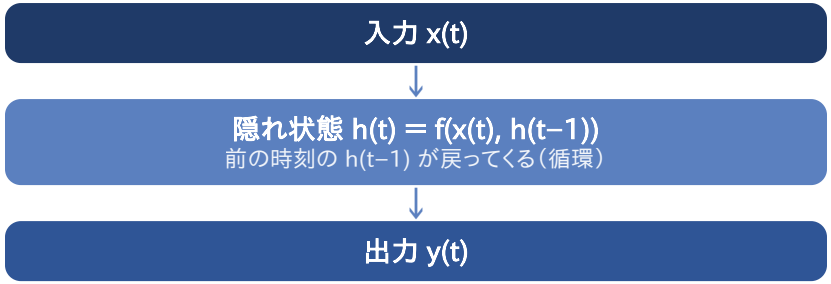
各ページの下に、根拠にした資料（JDLA のシラバス、Attention Is All You Need・Bahdanau ほか・Seq2Seq・RNN Encoder-Decoder の論文、ウィキペディア）を書いた。『』の中は原文どおり

第1章

RNN の基本

前の時刻の状態を持ち越して、順番のあるデータを扱う。

RNN のしくみ



名前	文脈ユニットに戻すもの
エルマン（1990）	隠れ層の値
ジョルダン（1986）	出力層の値

まとめて単純回帰型ネットワーク（SRN）。
双方向 RNN＝前から読む RNN＋後ろから読む RNN。

出典：ウィキペディア「回帰型ニューラルネットワーク」『ジョーダン（英語版）ネットワークはエルマンネットワークと似ている。文脈ユニットは隠れ層の代わりに出力層から入力を得る。』

RNN の学習

言葉	中身
BPTT	時刻ごとに展開し、時間をさかのぼって誤差逆伝播法
教師強制	学習時、次の入力に予測ではなく正解を入れる（学習が速い。推論時とずれる）
勾配消失	さかのぼるほど勾配が小さく、遠い過去を学べない → LSTM・GRU
勾配爆発	勾配が大きくなりすぎる → 勾配クリッピング

出典：英語版ウィキペディア「Backpropagation through time」『Backpropagation through time (BPTT) is a gradient-based technique for training certain types of recurrent neural networks, such as Elman networks.』／「Teacher forcing」

LSTM と GRU

	LSTM（1997年）	GRU（2014年）
ゲート	入力・忘却（1999年に追加）・出力	更新・リセット（出力ゲートなし）
記憶	記憶セル＋隠れ状態	隠れ状態だけ
パラメータ	多い	少ない

ゲート＝シグモイドの 0〜1 を掛けて、通す量を調整する。

セルの中を勾配がほぼそのまま流れる → 勾配消失を部分的に解決。

出典：ウィキペディア「長・短期記憶」『一般的なLSTMユニットは、記憶セル、入力ゲート、出力ゲート、および忘却ゲートから構成される。』／「ゲート付き回帰型ユニット」

第2章

Seq2Seq と Attention

文全体を1つのベクトルに押しこむのをやめ、必要なところを見に行く。

Seq2Seq から Attention へ

Seq2Seq（2014）
エンコーダの LSTM → 固定長ベクトル → デコーダの LSTM

固定長のベクトルがボトルネック。長い文で性能が落ちる。

↓ Bahdanau ほか（2014）

Attention つき
出力を作るたびに、入力のどこに注目するかを重みで選ぶ

要素	役割
クエリ Q	何を探しているか
キー K	見出し。Q との一致度 → ソフトマックスで重み
バリュー V	中身。重み付き和をとる

重みは入力ごとに変わる「ソフトウェイト」。

出典：Bahdanau ほか『we conjecture that the use of a fixed-length vector is a bottleneck in improving the performance of this basic encoder-decoder architecture』／ウィキペディア「アテンション」

第3章

Transformer

Attention だけで作る。並列に計算できて速い。

Transformer の部品

エンコーダ
Self-Attention ＋ フィードフォワード層

デコーダ
マスク付き Self-Attention ＋ Source-Target Attention ＋ フィードフォワード層

入力：単語の埋め込み ＋ 位置エンコーディング

部品	役割
Self-Attention	同じ列の中の関係（Q・K・V を同じ列から）
Source-Target	Q はデコーダ、K・V はエンコーダから
Multi-Head	ヘッドを複数並べ、いろいろな関連を同時に
位置エンコーディング	Attention は順番を区別しないので必須
マスク	未来の単語を見ない

出典：Vaswani ほか『based solely on attention mechanisms, dispensing with recurrence and convolutions entirely.』／ウィキペディア「Transformer」

本番での問われ方

ねらい	見るところ
RNN	循環と時系列、エルマンとジョルダン、双方向、BPTT、教師強制、勾配の問題
LSTM・GRU	3つのゲートの役割、GRU との違い（ゲート数・パラメータ）
Attention	固定長ベクトルの問題、クエリ・キー・バリュー、Source-Target
Transformer	並列化、Self-Attention、Multi-Head、位置エンコーディング、マスク

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」22. 回帰結合層／23. Attention