G検定（JDLA ジェネラリスト検定）　シラバス2024　26　#14

画像認識

物体識別・物体検出・セマンティック／インスタンス／パノプティックセグメンテーション・姿勢推定、AlexNet・VGG・GoogLeNet・ResNet・Wide ResNet・DenseNet・SENet・MobileNet・NAS・MnasNet・EfficientNet・Vision Transformer、R-CNN・Fast／Faster／Mask R-CNN・YOLO・SSD・FPN、FCN・SegNet・U-Net・PSPNet・DeepLab・OpenPose

各ページの下に、根拠にした資料（JDLA のシラバス、各モデルの原論文の要旨）を書いた。『』の中は原文どおり

第1章

画像認識のタスク

何が写っているか → どこにあるか → 画素ごとに何か。

タスクのちがい

タスク	出力	代表モデル
物体識別（分類）	画像全体に1クラス	AlexNet・ResNet・ViT
物体検出	物ごとの枠（バウンディングボックス）＋クラス	Faster R-CNN・YOLO・SSD
セマンティック	画素ごとのクラス（同じクラスは区別しない）	FCN・U-Net・DeepLab
インスタンス	物ごとの領域（1つずつ区別）	Mask R-CNN
パノプティック	セマンティック＋インスタンス	—
姿勢推定	関節の位置とつながり	OpenPose

出典：Kirillov ほか『Panoptic segmentation unifies the typically distinct tasks of semantic segmentation (assign a class label to each pixel) and instance segmentation (detect and segment each object instance).』

第2章

画像分類のモデル

深く → 近道 → 密に・幅広く → 自動で探す → Transformer へ。

分類モデルの系譜

年	モデル	キーワード
2012	AlexNet	ILSVRC 優勝。ReLU・ドロップアウト・GPU。畳み込み5＋全結合3
2014	VGG	3×3 だけで 16〜19 層
2014	GoogLeNet	Inception（並列の畳み込み）。ILSVRC 優勝
2015	ResNet	スキップ結合で 152 層。ILSVRC 優勝
2016	Wide ResNet／DenseNet	浅く幅広く／全部の後ろの層へ連結（L(L+1)/2 本）
2017	SENet／MobileNet	チャネルごとの重み（SE ブロック）／Depthwise Separable
2016〜19	NAS・MnasNet・EfficientNet	構造を自動探索（強化学習・レイテンシ）／深さ・幅・解像度を複合係数で
2020	Vision Transformer	16×16 のパッチの列を Transformer で

出典：Simonyan・Zisserman（VGG）『pushing the depth to 16-19 weight layers』／Tan・Le（EfficientNet）／Dosovitskiy ほか（ViT）

第3章

物体検出

2段階で丁寧に、1段階で速く。

2段階と1段階

R-CNN
候補の領域ごとに CNN（遅い）

↓ 画像全体を1回だけ CNN に

Fast R-CNN
学習 9倍・テスト 213倍速く

↓ 候補も CNN（RPN）で

Faster R-CNN

↓ マスクの枝を追加

Mask R-CNN（インスタンスセグメンテーション）

YOLO
画像全体を1回見て、枠とクラスを回帰。リアルタイム

SSD
複数の特徴マップ × デフォルトボックス

> FPN：深い層の特徴を上から下へ流し、どの大きさの物も見つけやすく（部品）。

出典：Ren ほか（Faster R-CNN）『we introduce a Region Proposal Network (RPN) that shares full-image convolutional features with the detection network』／Redmon ほか（YOLO）

セグメンテーションと姿勢推定

モデル	特徴
FCN	全部を畳み込み層に。どんな大きさの入力でも同じ大きさの出力
SegNet	VGG16 のエンコーダ＋デコーダ。プーリングの位置でアップサンプリング
U-Net	縮小と拡大の U 字＋スキップ結合。少ない画像から（医療画像）
PSPNet	ピラミッドプーリングで全体の文脈
DeepLab	Atrous Convolution で解像度を保って視野を広げる
OpenPose	PAF で部位を人に結びつける。複数人をリアルタイム（ボトムアップ）

出典：Ronneberger ほか（U-Net）『a contracting path to capture context and a symmetric expanding path that enables precise localization.』／Long ほか（FCN）／Chen ほか（DeepLab）／Cao ほか（OpenPose）

本番での問われ方

ねらい	見るところ
タスク	検出・セマンティック・インスタンス・パノプティック・姿勢推定の出力のちがい
分類モデル	年代順と一言の特徴（3×3、Inception、残差、密結合、SE、複合係数、パッチ）
物体検出	2段階（R-CNN 系の改良点）と1段階（YOLO・SSD）、FPN
セグメンテーション	FCN・SegNet・U-Net・PSPNet・DeepLab の工夫、OpenPose の PAF

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」26. 画像認識