G検定（JDLA ジェネラリスト検定）　シラバス2024　29・30　#16

深層強化学習とデータ生成

DQN・ダブル DQN・デュエリング・ノイジーネット・Rainbow・Ape-X・Agent57、A3C・PPO・連続値制御・報酬成形、OpenAI Five・AlphaStar・MARL・RLHF、sim2real・ドメインランダマイゼーション・残差強化学習・オフライン強化学習・状態表現学習、GAN・DCGAN・Pix2Pix・CycleGAN・拡散モデル・NeRF

第1章

DQN とその改良

Q学習 × CNN → 安定させる工夫 → 改良の組み合わせ。

DQN のしくみ

ゲームの画面（画素）

↓ CNN

行動ごとの Q 値（将来の報酬の見積もり）

↓ いちばん大きい行動を選ぶ

行動 → 報酬・次の画面

経験再生
経験をためてランダムに取り出す。データの相関を弱める

ターゲットネットワーク
目標の値を、少し前の重みで固定して計算

どちらも学習を安定させる工夫。

出典：Mnih ほか（DQN）『The model is a convolutional neural network, trained with a variant of Q-learning, whose input is raw pixels and whose output is a value function estimating future rewards.』

DQN の改良

手法	改良点
ダブル DQN	選ぶネットワークと評価するネットワークを分け、過大評価を減らす
デュエリング	状態価値 V とアドバンテージ A に分けて推定
ノイジーネット	重みにノイズ → ε -greedy の代わりに探索
Rainbow	6つの改良を組み合わせる
Ape-X	多数のアクター＋1つの学習器。優先度つき経験再生（分散）
Agent57	Atari の57ゲームすべてで人間の基準を超えた

出典：Hessel ほか（Rainbow）『This paper examines six extensions to the DQN algorithm and empirically studies their combination.』

第2章

方策の学習と応用

Actor-Critic・方策勾配 → ゲーム → 言語モデル。

方策を学ぶ手法

A3C
複数のアクター・学習器が並列・非同期に。CPU 1台で

PPO
方策の変化を小さく抑える。TRPO より簡単

DDPG（連続値制御）
関節のトルクなど連続の行動

報酬成形
補助の報酬を足して学習を速くする

> DQN は行動が離散のとき。連続の行動は方策勾配系（DDPG・PPO）。

出典：Schulman ほか（PPO）『The new methods, which we call proximal policy optimization (PPO), have some of the benefits of trust region policy optimization (TRPO), but they are much simpler to implement』

ゲームと言語への応用

事例	中身
OpenAI Five	Dota 2 で世界王者に勝つ（2019年4月）。自己対戦・10か月
AlphaStar	StarCraft II でグランドマスター（2019年8月）。DeepMind
MARL	同じ環境に学習するエージェントが複数
RLHF	人の比較 → 報酬モデル → PPO で調整。InstructGPT・ChatGPT

出典：ウィキペディア日本語版「人間のフィードバックによる強化学習」『人間のフィードバック（反応）から直接に「報酬モデル」を訓練し、そのモデルを報酬関数として使用して』

ロボットと実世界

用語	中身
sim2real	シミュレーションで学び、実機に移す（リアリティギャップが課題）
ドメインランダマイゼーション	見た目・物理をランダムに。実世界を「変化のひとつ」に
残差強化学習	従来の制御＋残差だけ強化学習。2つの信号の和
オフライン強化学習	集めたデータだけ。新たにデータを集めない
状態表現学習	行動で変わる特徴を低い次元で

出典：Tobin ほか『With enough variability in the simulator, the real world may appear to the model as just another variation.』

第3章

データ生成

競わせる（GAN）・ノイズを除く（拡散）・場面を表す（NeRF）。

GAN のしくみ



G は D がまちがえる確率を最大に、D は見分けるように学ぶ（ミニマックスゲーム）。

理想の解：G が訓練データの分布を再現し、D はどこでも 1/2。

失敗の例：いつも同じものしか出ない（モード崩壊）。

出典：Goodfellow ほか（GAN）『The training procedure for G is to maximize the probability of D making a mistake.』

生成モデルのちがい

モデル	中身
DCGAN	制約つきの CNN で GAN
Pix2Pix	ペアの画像で画像 → 画像（条件つき GAN）
CycleGAN	ペアなし。F(G(X)) ≒ X のサイクル一貫性損失
拡散モデル	ノイズを加える過程を逆にたどる。DALL-E 2 など
NeRF	5次元の座標 → 密度と色。新しい視点の画像

出典：Zhu ほか（CycleGAN）／ウィキペディア日本語版「拡散モデル」『拡散過程を反転させる学習を通じて訓練されたニューラルネットワークに相当する』

本番での問われ方

ねらい	見るところ
DQN 系	経験再生・ターゲットネットワーク、ダブル・デュエリング・ノイジー・Rainbow・Ape-X・Agent57
方策系と応用	A3C・PPO・連続値制御、OpenAI Five・AlphaStar、RLHF
実世界	sim2real・ドメインランダマイゼーション・残差・オフライン
生成	GAN の G と D、Pix2Pix（ペア）と CycleGAN（ペアなし）、拡散モデル、NeRF

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」29. 深層強化学習・30. データ生成