G検定（JDLA ジェネラリスト検定）　シラバス2024　35･36　#18

AIプロジェクトとデータ

AI のビジネス活用･BPR･PoC･CRISP-DM･CRISP-ML･ウォーターフォール･アジャイル･ステークホルダー･データサイエンティスト･オープン･イノベーション･産学連携、Python･Jupyter Notebook･Docker･クラウド･Web API･MLOps･コンセプトドリフト、オープンデータセット･コーパス･アノテーション･データリーケージ･正規化･標準化

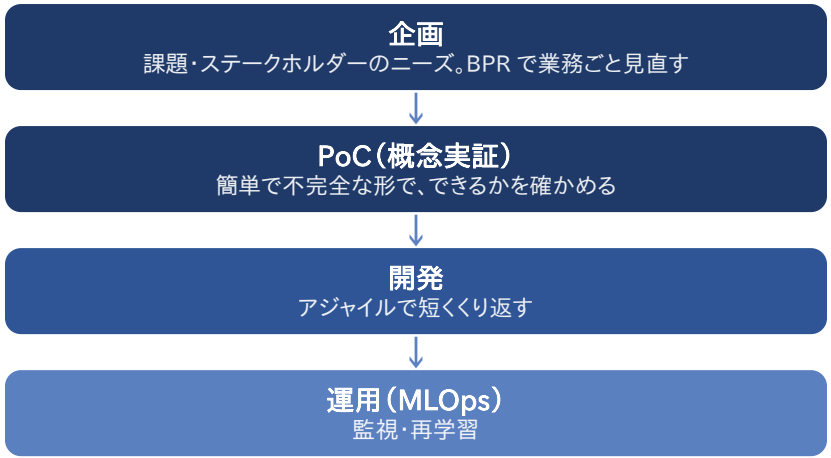
各ページの下に、根拠にした資料（JDLA のシラバス、論文の要旨、ウィキペディア）を書いた。『』の中は原文どおり

第1章

AI プロジェクトの進め方

課題を決める → 小さく試す → 作る → 運用する。

プロジェクトの流れ



AI を使うこと自体を目的にしない。

PoC をくり返して先に進まない「PoC 貧乏」に注意。

データ・技術・人材は、オープン・イノベーションや産学連携で補う。

出典：ウィキペディア日本語版「概念実証」『新たな概念やアイデアの実現可能性を示すために、簡単かつ不完全な実現化（または概要）を行うこと。』

CRISP-DM と CRISP-ML



CRISP-DM：データマイニングの標準のプロセス。行き来しながら進める。もっとも広く使われる。

CRISP-ML(Q)：機械学習向け。最初にビジネスとデータの理解をまとめ、最後に監視と保守。

出典：Studer ほか『The first phase combines business and data understanding as data availability oftentimes affects the feasibility of the project.』

開発の進め方

	ウォーターフォール	アジャイル
進め方	要件 → 設計 → 実装 → テストの順。後戻りしない前提	短いイテレーションで計画・実装・リリースをくり返す
向く場面	最初に要件を決めきれる	やってみないと分からない（AI 開発）

出典：ウィキペディア日本語版「アジャイルソフトウェア開発」『その価値を実現する成果物を短いイテレーションの中で計画・実装・デプロイすることで（⇒反復型開発）、迅速にプロダクトを届け価値の実証・学習・適応をおこなう。』

第2章

開発と運用の環境

試す・まとめる・届ける・見張る。

開発と運用の道具

道具	役割
Python	AI 開発の中心の言語。ライブラリが豊富
Jupyter Notebook	コード・文章・数式・図を1つの文書に。対話的に試す
Docker	コンテナで実行環境ごとまとめる。カーネルを共有するので軽い
クラウド	計算資源（GPU）をサービスとして使う
Web API	モデルを HTTP で呼べるようにする
MLOps	本番のモデルを確実に展開・保守。監視 → 再学習

コンセプトドリフト：時間とともにデータが変わり、モデルが合わなくなる。ヘルスモニタリングで見張る。

出典：ウィキペディア英語版「MLOps」『MLOps or ML Ops is a paradigm that aims to deploy and maintain machine learning models in production reliably and efficiently.』

第3章

データの収集と加工

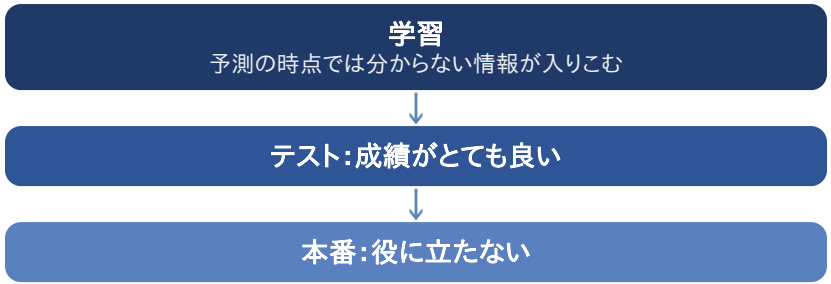
集める → ラベルをつける → 整える。漏れに注意。

データの用語

用語	中身
オープンデータセット	公開のデータ（ImageNet・MNIST・COCO）。ライセンスを確認
コーパス	言語の分析のための大量の文章のデータ
アノテーション	正解ラベルなどの情報をつける。人・システム・両方
正規化	最小 0・最大 1 に（min-max）
標準化	平均 0・分散 1 に

出典：ウィキペディア英語版「Feature scaling」『Feature standardization makes the values of each feature in the data have zero-mean (when subtracting the mean in the numerator) and unit-variance.』

データリーケージ



例：解約の予測に「解約の手続きの日」を入れる。

例：テストデータもふくめて平均を計算して標準化する。

「予測のときにその情報はあるか」で確かめる。

出典：ウィキペディア英語版「Leakage (machine learning)」『refers to the use of information during model training that would not be available at prediction time.』

本番での問われ方

ねらい	見るところ
進め方	BPR・PoC・CRISP-DM の6段階・CRISP-ML、ウォーターフォールとアジャイル
人と組織	ステークホルダー・データサイエンティスト・オープン・イノベーション・産学連携
環境と運用	Jupyter・Docker・クラウド・Web API・MLOps・コンセプトドリフト
データ	コーパス・アノテーション・データリーケージ・正規化と標準化

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」35・36