G検定（JDLA ジェネラリスト検定）　シラバス2024　法律・倫理 9〜17　#24

AI倫理の論点

プライバシー・バイ・デザイン・カメラ画像利活用ガイドブック、アルゴリズムバイアス・サンプリングバイアス・センシティブ属性・代理変数・公平性の定義、敵対的攻撃・データ汚染・モデル窃取・データ窃取・セキュリティ・バイ・デザイン、ディープフェイク・フェイクニュース、説明可能性・データの来歴、フィルターバブル・エコーチェンバー、電力消費、AI との協働、インクルージョン・軍事利用・死者への敬意・人間の自律性

各ページの下に、根拠にした資料（AI 事業者ガイドライン、arXiv の論文、ウィキペディア日本語版・英語版）を書いた。カメラ画像利活用ガイドブックは原文を取得できなかったため要約した。『』の中は原文どおり

第1章

プライバシーと公平性

集めるときと推論するときを分ける。属性を消してもバイアスは残る。

プライバシー：収集と推論

データ収集段階
知らないうちに顔や行動が撮られる・集められる → 告知・目的の限定・最小限の収集

推論段階
購買履歴から妊娠・病気などを推測 → センシティブな推論をしない、結果の扱いを決める

プライバシー・バイ・デザイン
設計の段階から組みこむ（アン・カブキアン、7原則）

7原則：事前に／初期設定で保護／設計に組みこむ／ポジティブサム／全期間のセキュリティ／可視性と透明性／利用者の尊重。

カメラ画像利活用ガイドブック：撮影と目的の事前告知、保存期間を限る、目的外に使わない、問い合わせ窓口。

出典：ウィキペディア英語版「Privacy by design」『Proactive not reactive; preventive not remedial』

公平性：バイアスの原因

原因	中身	例
データの偏り	過去の差別や不均衡をそのまま学ぶ	Amazon の採用 AI が女性に不利（2015年に停止）
サンプリングバイアス	データが母集団を代表していない	顔認識：暗い肌の女性で誤り率34.7%
代理変数	センシティブ属性を消しても別の変数で推測	郵便番号が人種の代わりになる

> センシティブ属性（人種・性別・宗教など）の列を消すだけでは公平にならない。

出典：AI 事業者ガイドライン『人種や性別等の明らかなセンシティブ属性を取り除いたデータであっても、関連する情報からセンシティブ属性が類推されてしまう場合』

公平性の定義と COMPAS

ProPublica（2016年）
黒人の被告人の誤分類の割合が高い → 人種的な偏り

開発元
予測の正確さは人種にかかわらず同じ

結論
どちらも正しい。両立しない別々の公平性の定義を見ていた

主な定義：合格率をそろえる（デモグラフィック・パリティ）、誤り率をそろえる（均等化オッズ）、予測の当たり方をそろえる（較正）。

複数の定義を同時に満たすことは一般にできない。用途に合わせて選ぶ。

出典：ウィキペディア英語版「COMPAS (software)」『they refer to two mutually exclusive definitions of fairness.』

第2章

安全性・セキュリティ・悪用

学習をねらう攻撃、推論をねらう攻撃。偽物を作る悪用。

AI への攻撃

攻撃	段階	中身
敵対的攻撃	推論	小さく意図的なノイズで、高い確信度の誤認識
データ汚染	学習	誤りを増やすデータ・バックドアを混ぜる
モデル汚染	学習・配布	配布モデルや連合学習の更新に細工
モデル窃取	推論	問い合わせの出力からモデルを再現
データ窃取	推論	学習データを推測・復元（メンバーシップ推論など）

対策の考え方：セキュリティ・バイ・デザイン（設計の段階から組みこむ）。

出典：Goodfellow ほか（arXiv:1412.6572）『inputs formed by applying small but intentionally worst-case perturbations to examples from the dataset』

悪用：ディープフェイクとフェイクニュース

ディープフェイク
深層学習＋偽物。実在しない・改変された人物や出来事の精巧な合成メディア

フェイクニュース
事実と異なる情報をニュースのように広める

悪用：政治家の偽の演説、なりすまし詐欺、同意のない性的な画像、世論の操作。

対策：検出技術、電子透かし、来歴の記録、ファクトチェック、AI 生成物の表示、リテラシー教育。

出典：AI 事業者ガイドライン『生成 AI によって、内容が真実・公平であるかのように装った情報を誰でも作ることができるようになり』

第3章

透明性・民主主義・環境・労働・その他

ブラックボックスを開く。情報の泡を割る。人を取り残さない。

透明性と民主主義

説明可能性
どのように決定がなされたかに答えられる（技術は #17）

データの来歴
データの出どころ・集め方・加工の経歴

フィルターバブル
アルゴリズムの推薦で、見たい情報ばかりになる

エコーチェンバー
似た意見の人の集まりで、意見が肯定され増幅される

> 原因のちがい：フィルターバブル＝アルゴリズム、エコーチェンバー＝人の集まり。

出典：AI 事業者ガイドライン『説明可能性（システムでどのように決定がなされたかについて答えられること）』

環境・労働・その他の価値

論点	中身
環境保護	大きなモデルの学習で大量の電力・費用・CO2（Strubell ら 2019）
労働政策	AI との協働、スキルの喪失、労働力不足の補完、学び直し
インクルージョン	障害・年齢・言語にかかわらず恩恵を受けられ、取り残さない
軍事利用	LAWS：人間を介さず標的を判断する兵器。責任と生死の判断
死者への敬意	故人の声や姿の再現：本人の意思・遺族・尊厳
人間の自律性	推薦や操作的なデザインで、選択が気づかずに誘導されない

出典：Strubell ほか（arXiv:1906.02243）『these accuracy improvements depend on the availability of exceptionally large computational resources that necessitate similarly substantial energy consumption.』

本番での問われ方

ねらい	見るところ
プライバシー	収集段階と推論段階、プライバシー・バイ・デザイン、カメラ画像の告知
公平性	データの偏り・サンプリングバイアス・代理変数、Amazon・COMPAS、定義は両立しない
セキュリティ・悪用	敵対的攻撃・データ汚染・モデル窃取の区別、ディープフェイクの対策
そのほか	フィルターバブルとエコーチェンバーの区別、電力消費、LAWS、死者への敬意、自律性

出典：JDLA「G検定の試験出題範囲（シラバス）G2024#6〜」法律・倫理分野 9〜17